Universidad de San Carlos de Guatemala
Escuela de Estudios de Postgrado
Maestría en Ciencias de la Computación
con especialización en Ciencia de Datos
Análisis de Datos Avanzados
Eriksson José Hernández López
999017424

Informe Ejecutivo

Segmentación de Clientes para Campaña de Depósitos a Plazo

1. Resumen ejecutivo

El presente informe analiza el comportamiento de clientes de una institución financiera antes de una campaña de marketing telefónico orientada a la suscripción de depósitos a plazo. El objetivo principal fue identificar patrones relevantes mediante análisis exploratorio de datos y detectar segmentos naturales de clientes usando técnicas de clustering, con el fin de apoyar la toma de decisiones comerciales.

El análisis permitió identificar una estructura clara de **dos segmentos principales**. El primero agrupa a la mayoría de clientes, pero presenta una **muy baja tasa de conversión**, lo que indica menor eficiencia comercial para campañas intensivas. El segundo segmento, aunque más pequeño, presenta una **tasa de conversión significativamente superior**, asociada a un mejor historial de interacción previa y, por tanto, a una mayor oportunidad de respuesta positiva.

Desde el punto de vista metodológico, se utilizó **K-Means** como método principal de segmentación por su escalabilidad e interpretabilidad, y **clustering jerárquico con enlace Ward** como método de contraste y validación estructural. Ambos enfoques convergieron en una segmentación consistente, lo que fortalece la confiabilidad de los resultados.

En términos de negocio, el principal hallazgo es que no todos los clientes deben ser tratados de la misma manera dentro de una campaña telefónica. La evidencia sugiere que una estrategia diferenciada por segmento permitiría mejorar la eficiencia comercial, reducir esfuerzo operativo innecesario y concentrar recursos en los clientes con mayor probabilidad de conversión.

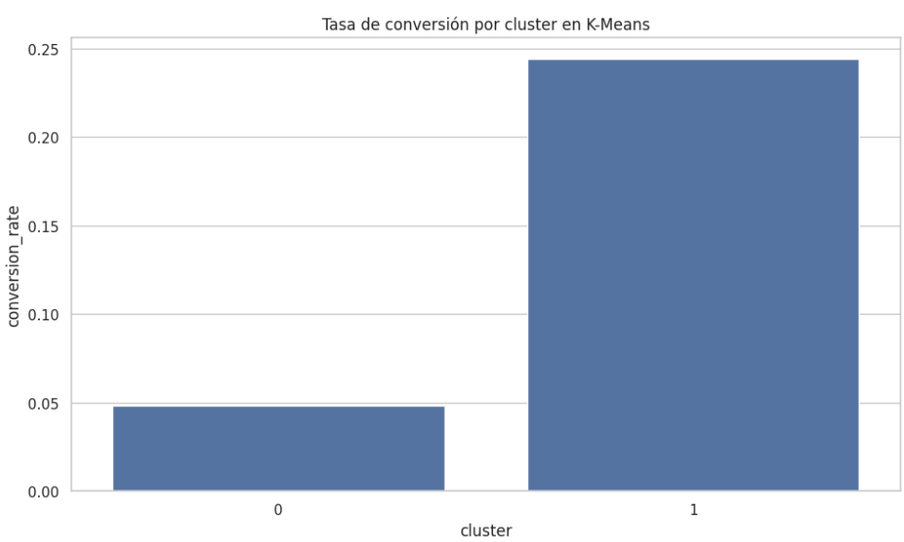

Figura 1: gráfico de tasa de conversión por cluster.

2. Hallazgos del análisis exploratorio de datos (EDA)

2.1 Calidad y estructura del dataset

El dataset analizado contiene **41,188 registros y 21 variables**, incluyendo variables demográficas, financieras, de interacción comercial, indicadores económicos y la variable objetivo y, que representa si el cliente suscribió o no un depósito a plazo.

En términos de calidad de datos, no se encontraron valores nulos explícitos en esta versión del conjunto analizado. Esto permitió desarrollar el proceso de preparación sin necesidad de imputaciones complejas. Aun así, el diagnóstico de calidad siguió siendo relevante, ya que permitió confirmar la consistencia estructural del dataset y validar que las variables estaban disponibles para un análisis completo.

2.2 Hallazgos univariados

El análisis univariado mostró que varias variables numéricas presentan distribuciones asimétricas y concentraciones importantes en ciertos valores. En particular, `campaign`, `previous`, `pdays` y `duration` presentaron comportamientos extremos que debían ser interpretados con cuidado. No se asumió automáticamente que estos valores fueran errores, ya que varios de ellos reflejan la lógica operativa de campañas previas.

La variable `pdays` destaca especialmente, ya que el valor `999` aparece de forma dominante y representa clientes que no habían sido contactados recientemente. Este comportamiento no debe considerarse ruido, sino una señal de negocio importante sobre el historial relacional del cliente.

2.3 Outliers y lectura analítica

La detección de outliers por IQR y Z-Score mostró que las variables con mayor proporción de valores extremos fueron `previous`, `duration`, `campaign` y `pdays`. Esta observación es importante porque evidencia que el comportamiento del cliente no es homogéneo y que existen patrones de interacción muy distintos entre grupos.

Sin embargo, estos outliers no fueron eliminados de forma automática, ya que hacerlo habría implicado perder información relevante para la segmentación. En este caso, los valores extremos forman parte del fenómeno comercial que se busca entender.

2.4 Hallazgos bivariados y multivariados

La matriz de correlación mostró una **alta redundancia estructural** entre variables económicas. Las relaciones más fuertes se observaron entre `emp.var.rate` y `euribor3m` (**0.9722**), entre `euribor3m` y `nr.employed` (**0.9452**) y entre `emp.var.rate` y `nr.employed` (**0.9070**). Esto indica que parte del contexto macroeconómico del dataset está representado por variables estrechamente relacionadas, por lo que deben interpretarse como un bloque contextual común.

El análisis PCA reforzó esta idea. Las primeras 10 componentes explicaron aproximadamente **75.11 % de la varianza acumulada**, lo que indica que la estructura del dataset es claramente multivariada y no puede resumirse de forma adecuada en muy pocas dimensiones sin pérdida de información sustancial.

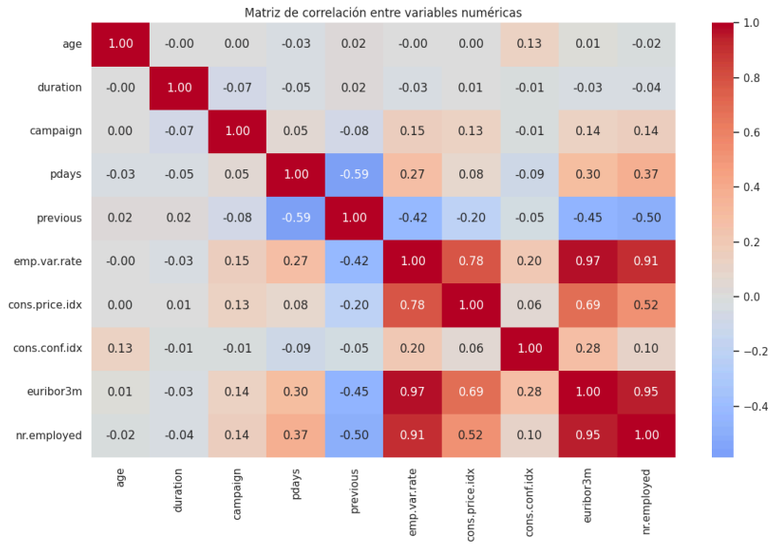

Figura 2: matriz de correlación entre variables numéricas.

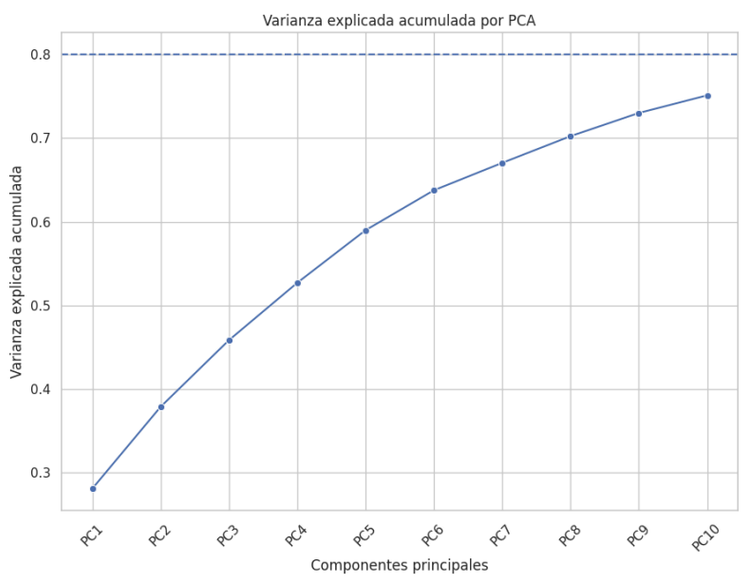

Figura 3: gráfica de varianza explicada acumulada por PCA.

3. Preparación de datos y justificación técnica del modelo

3.1 Selección y tratamiento de variables

Para la construcción de la segmentación se excluyó la variable `duration`. Esta decisión fue metodológicamente necesaria porque dicha variable sólo se conoce después de realizada la llamada, por lo que usarla en la segmentación introduciría información no disponible al momento de planificar la campaña. En consecuencia, mantenerla dentro del modelo habría generado una ventaja artificial y poco realista desde el punto de vista operativo.

Las variables categóricas fueron transformadas mediante **One-Hot Encoding**, lo cual permitió representar categorías nominales sin imponer relaciones de orden inexistentes. Las variables numéricas fueron estandarizadas con **StandardScaler**, con el objetivo de evitar que diferencias de escala dominaran la distancia euclidiana usada por los algoritmos de agrupamiento.

3.2 Justificación de K-Means

K-Means fue seleccionado como el método principal por tres razones que lo diferencian del resto de algoritmos:

1. Por su capacidad de escalar adecuadamente sobre el conjunto completo de datos.
2. Por su facilidad de interpretación una vez obtenidos los perfiles de cluster.
3. Por su utilidad práctica para futuros procesos de segmentación periódica o integración con procesos analíticos de negocio.

Para determinar el número óptimo de clusters se utilizaron dos criterios complementarios: el **método del codo** y el **Silhouette Score**. Ambos sugirieron que la solución más adecuada era **k = 2**. Aunque k = 3 mostró un comportamiento relativamente cercano, la mejora no fue suficiente para justificar mayor complejidad analítica ni menor claridad en la interpretación de segmentos.

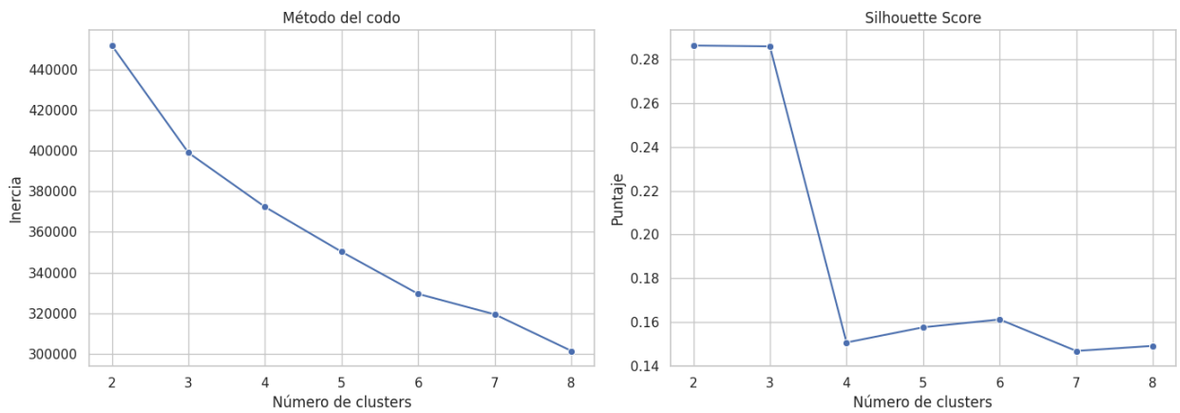

Figura 4: gráfico combinado de método del codo y Silhouette Score.

3.3 Justificación del método jerárquico

Como segundo método de segmentación se utilizó **clustering jerárquico aglomerativo con enlace Ward**. Esta elección se justifica porque Ward minimiza la varianza intra cluster y permite evaluar visualmente la estructura del agrupamiento mediante el dendrograma.

El objetivo de este segundo método no fue reemplazar a K-Means, sino validar si la estructura encontrada por el método principal era consistente. En este caso, el clustering jerárquico confirmó la existencia de dos grandes grupos claramente diferenciados.

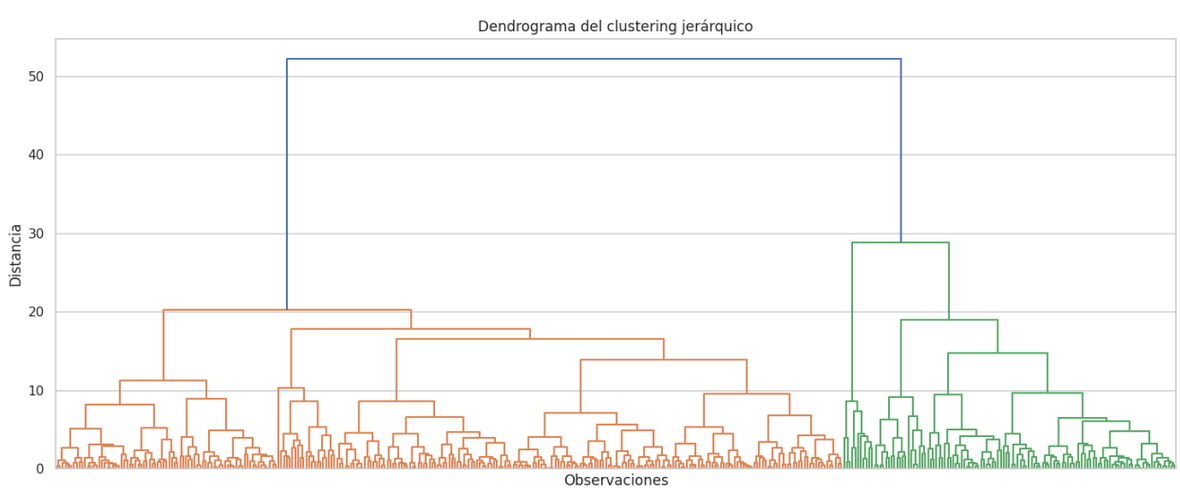

Figura 5: dendrograma del clustering jerárquico.

4. Perfil detallado de segmentos

4.1 Segmento 0: clientes de baja respuesta y baja vinculación previa

El **Cluster 0** agrupa **27,653 clientes**, equivalentes al **67.14 %** del total. Es el segmento más grande, pero presenta una tasa de conversión de solo **4.83 %**, por lo que representa el grupo menos eficiente para campañas telefónicas orientadas a depósitos a plazo.

Su comportamiento comercial se caracteriza por una **muy baja interacción previa efectiva**, evidenciada en un promedio de `previous = 0.025` y en un valor medio de `pdays = 999`, lo que sugiere ausencia de contacto reciente o vínculo comercial previo poco desarrollado. Además, este grupo presenta un promedio mayor de contactos por campaña (`campaign = 2.80`), lo que sugiere mayor esfuerzo comercial con menor retorno.

Desde la perspectiva económica, este cluster se asocia con valores más altos en `emp.var.rate`, `euribor3m` y `nr.employed`, lo que indica que su comportamiento se observó en un contexto económico diferente al del segmento de mayor conversión.

En términos estratégicos, este grupo debe entenderse como un segmento de **baja afinidad comercial inmediata**. No conviene priorizar en campañas intensivas sin aplicar filtros adicionales o estrategias de menor costo.

4.2 Segmento 1: clientes con mayor oportunidad comercial

El **Cluster 1** reúne **13,535 clientes**, equivalentes al **32.86 %** del total, y presenta una tasa de conversión de **24.41 %**, considerablemente superior a la del segmento anterior.

Su principal característica es un **mayor historial relacional**, reflejado en un valor promedio más alto de `previous = 0.475` y un valor de `pdays` menor que el del Cluster 0. Esto sugiere clientes con mayor exposición previa a interacciones comerciales o con una relación más madura con la institución.

Además, este segmento requiere menos presión comercial relativa, pues su promedio de contactos por campaña es menor (`campaign = 2.09`) y aun así obtiene una respuesta mucho más favorable. Desde el punto de vista comercial, este es el grupo con mayor potencial para campañas telefónicas de depósitos a plazo.

En términos estratégicos, se trata del segmento que debe recibir **prioridad** dentro de la campaña, tanto por su mayor probabilidad de conversión como por la mejor relación esperada entre esfuerzo y resultado.

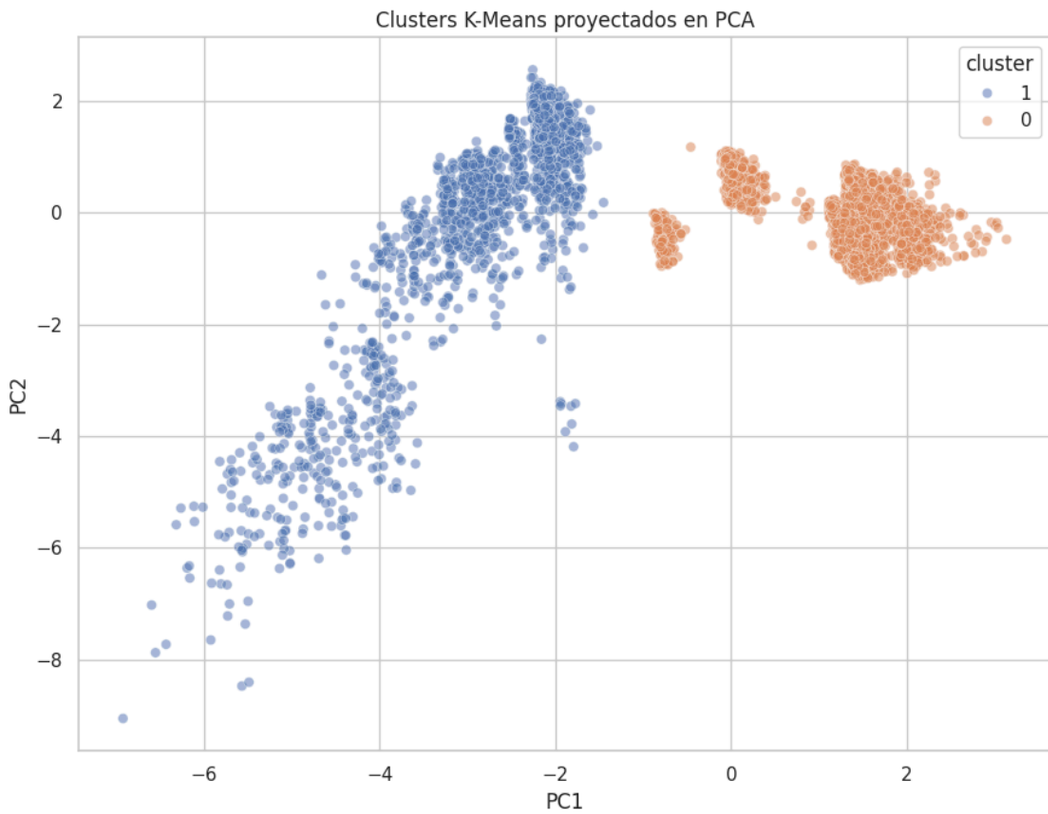

Figura 6: proyección PCA con clusters de K-Means.

Tabla 1. Resumen comparativo de segmentos

Variable	Cluster 0	Cluster 1
Participación en la muestra	67.14 %	32.86 %
Tasa de conversión	4.83 %	24.41 %
Campaign promedio	2.80	2.09
Pdays promedio	999.00	887.85
Previous promedio	0.025	0.475
Lectura estratégica	Baja respuesta	Alta oportunidad

5. Comparación entre métodos de segmentación

La comparación entre métodos mostró que ambos modelos convergen en una misma lectura general del problema: existen **dos grupos principales de clientes** con comportamientos claramente diferenciados.

K-Means obtuvo un **Silhouette Score de 0.2863**, mientras que el clustering jerárquico alcanzó **0.3793** sobre la muestra utilizada. Esto indica que el método jerárquico logró una separación geométrica más fuerte en términos relativos. Sin embargo, esta ventaja no es suficiente para desplazar a K-Means como método principal, ya que el primero tiene un costo computacional mayor y menor escalabilidad sobre el dataset completo.

En consecuencia, la mejor decisión metodológica consiste en usar **K-Means como modelo principal de segmentación** y el **clustering jerárquico como herramienta de validación estructural**. Esta combinación equilibra calidad analítica, interpretabilidad y viabilidad práctica.

Tabla 2. Comparación entre métodos

Criterio	K-Means	Clustering Jerárquico
Supuestos	Clusters compactos y aproximadamente esféricos	Estructura jerárquica por fusiones sucesivas
Sensibilidad a outliers	Alta	Media a alta
Escalabilidad	Alta	Menor
Interpretabilidad	Alta	Muy alta
Calidad del cluster	Silhouette = 0.2863	Silhouette = 0.3793
Rol en el proyecto	Método principal	Método de validación

6. Recomendaciones estratégicas

A partir de la segmentación obtenida, se recomienda adoptar una estrategia comercial diferenciada:

- Para el **Segmento 1**, la recomendación es priorizar campañas telefónicas directas, seguimiento comercial y ofertas focalizadas, ya que concentra la mayor probabilidad de conversión y muestra una relación más favorable entre historial relacional y respuesta positiva.

- Para el **Segmento 0**, la recomendación es evitar campañas intensivas indiscriminadas. En su lugar, conviene aplicar filtros adicionales, estrategias de precalificación o acciones de menor costo, dado que su tasa de conversión es baja y el esfuerzo comercial requerido tiende a ser mayor.

En conjunto, la segmentación permite asignar mejor los recursos comerciales, reducir contactos de bajo valor esperado y aumentar la eficiencia general de la campaña.

7. Métricas utilizadas y explicación formal

Para asegurar rigor técnico en la evaluación del modelo, se utilizaron las siguientes métricas y criterios:

- **Método del codo:** se utilizó para evaluar la reducción de la inercia a medida que aumenta el número de clusters. Su propósito es identificar el punto a partir del cual agregar más clusters produce ganancias marginales decrecientes.

- **Inercia:** mide la suma de distancias cuadradas entre cada observación y el centroide de su cluster. Valores menores indican clusters más compactos, aunque por sí sola no determina el número óptimo de grupos.

- **Silhouette Score:** evalúa simultáneamente la cohesión interna y la separación entre clusters. Su valor oscila entre -1 y 1. Valores más cercanos a 1 indican mejor agrupamiento, mientras que valores cercanos a 0 sugieren solapamiento entre grupos.

- **PCA:** se empleó como herramienta de reducción de dimensionalidad y visualización. Permitió evaluar cuánta varianza del dataset puede explicarse en un espacio reducido y facilitó la inspección visual de la separación entre clusters.

- **Dendrograma:** en el método jerárquico, se utilizó para analizar la estructura de agrupación y validar si el número de clusters seleccionado respondía a un corte natural o forzado.

8. Conclusiones

El análisis realizado demuestra que la base de clientes no es homogénea y que puede segmentarse de forma consistente en **dos grandes grupos** con distinto potencial comercial. Esta estructura fue respaldada tanto por K-Means como por clustering jerárquico, lo que aumenta la robustez de la solución.

El principal aporte del proyecto es evidenciar que la campaña de depósitos a plazo no debería dirigirse de manera uniforme a toda la cartera. Existe un segmento amplio con baja probabilidad de conversión y otro más pequeño, pero significativamente más valioso, que debe convertirse en la prioridad de la estrategia comercial.

En consecuencia, la segmentación propuesta no solo cumple una función analítica, sino que ofrece una base concreta para mejorar la eficiencia de futuras campañas, optimizar el uso de recursos y orientar la toma de decisiones con mayor precisión.

9. Anexos

Enlace del Repositorio: https://github.com/ErikssonHerlo/Bank-Customer-Segmentation